Aufgabe 1A · Niklas · 12.11.2026

Wie viel optionale Analyse verträgt der Anwendungshost?

spaCy als kontrollierter Vergleich für Ressourcenisolation.

> Niedrige absolute Latenzen genügen nicht, wenn die vorab festgelegten relativen Regeln verfehlt werden.

Systemgrenzen fachlich trennen

Baustein	Rolle
spaCy	Eigener Sidecar für sprachliche Glättung.
8.9b / Kontextaufbau	Arbeit im Backend-Prozess.
Encoder	Eigener Embedding-Sidecar; hier aus.
Generative Inferenz	Eigene private Serverrolle nach ADR-0035.

App, PostgreSQL und Redis ohne zusätzliche Limits; PDF-Worker aktiv. Ein spaCy-Ergebnis bestätigt keine LLM-Tragfähigkeit.

Fünf Varianten, fünf gepaarte Blöcke

V0	Live ohne Analyse.	**V1**	Analyse, spaCy aus.
V2	spaCy: 1 CPU / 1 GiB.	**V3**	spaCy: 0,25 CPU.
V4	6000 ms Weiterleitungsverzögerung, 5000 ms Timeout.		

- 60 s Aufwärmung; 300 s Messfenster; 500 Beitritte über 90 s.
- 500 Quiz-, 100 Q&A- und 500 Tempostimmen; Freigabe bei 270 s.
- Fünf Analyse-Hosts, 150 Termine, identische synthetische Korpora.

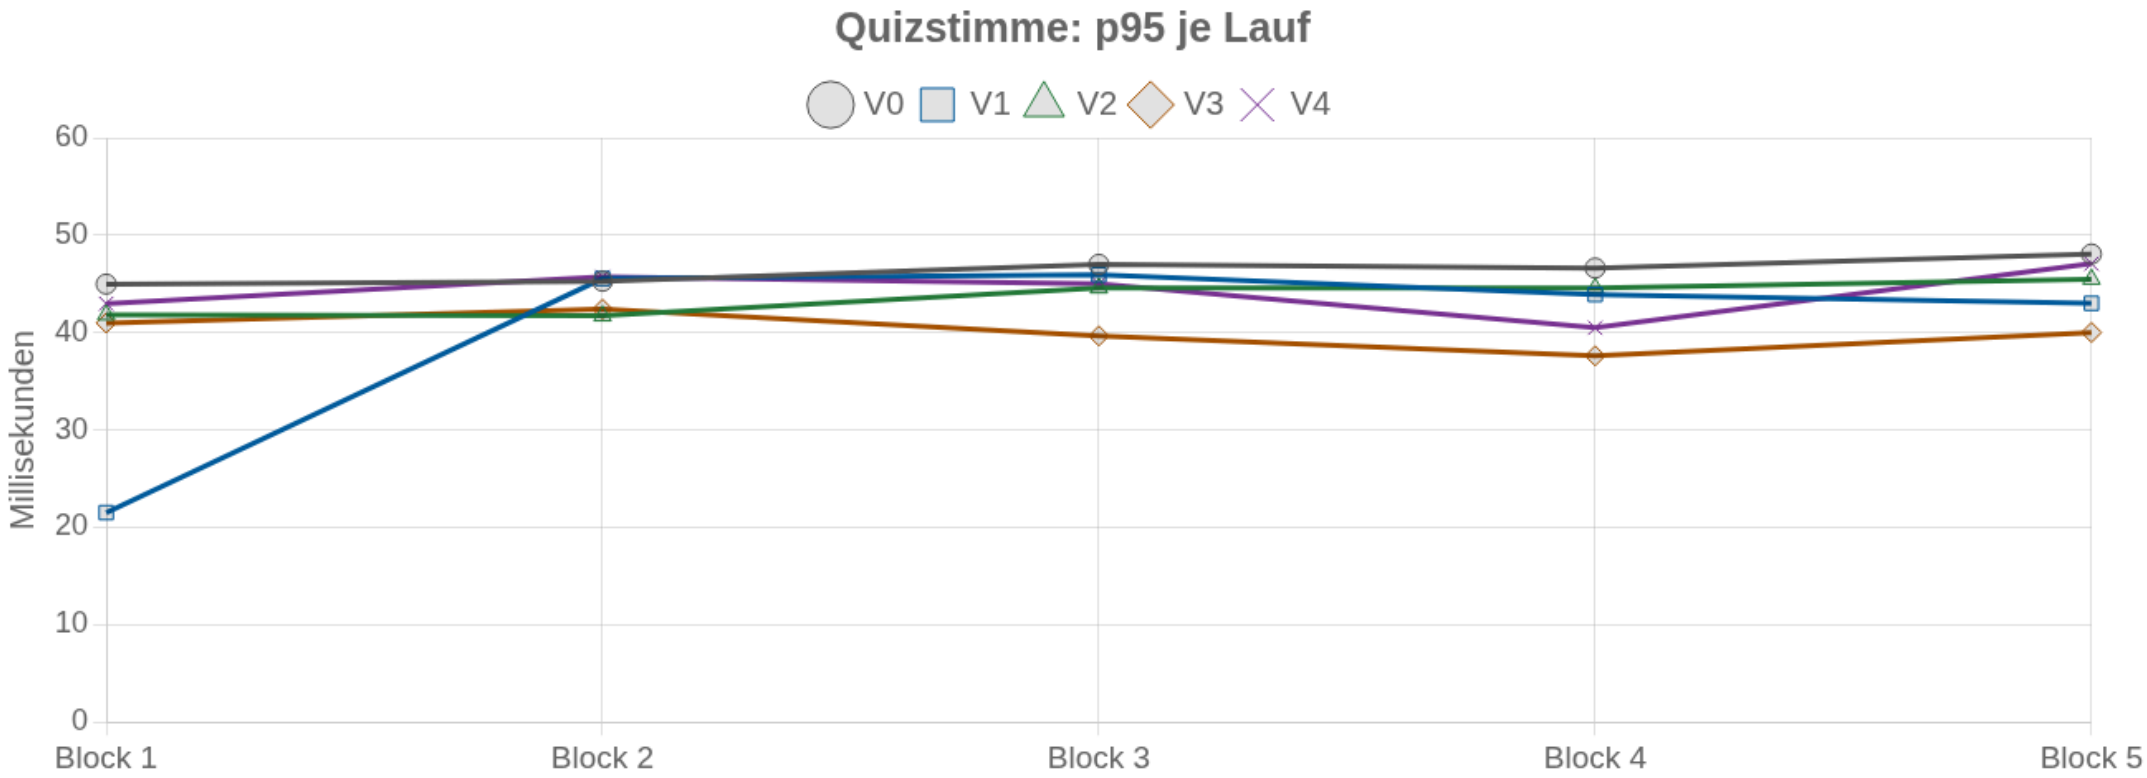
WSL2, 16 logische CPUs; Generator auf demselben Rechner. Anwendung unverändert aus festgehaltenem main, Version 1.4.0.

Die Regeln stehen vor der Messung fest

- Je Aktion: p95-Anstieg ≤ 10 % **und** ≤ 50 ms gegenüber V1 desselben Blocks.
- Fehler und fehlende geplante Arbeit jeweils ≤ 0,5 %.
- Alle fünf Wiederholungen müssen bestehen; keine Ausreißer entfernen.
- Analyseverfügbarkeit, RAM, Drosselung und OOM separat prüfen.

> Erfassung vollständig ≠ Leistungsgrenzen erfüllt.

Absolute Quiz-Latenzen bleiben niedrig



Höchster Lauf-p95: 48,07 ms bei Ziel ≤ 1000 ms. 40000 / 40000 geplante Live-Aktionen erfolgreich; keine Fehlversuche.

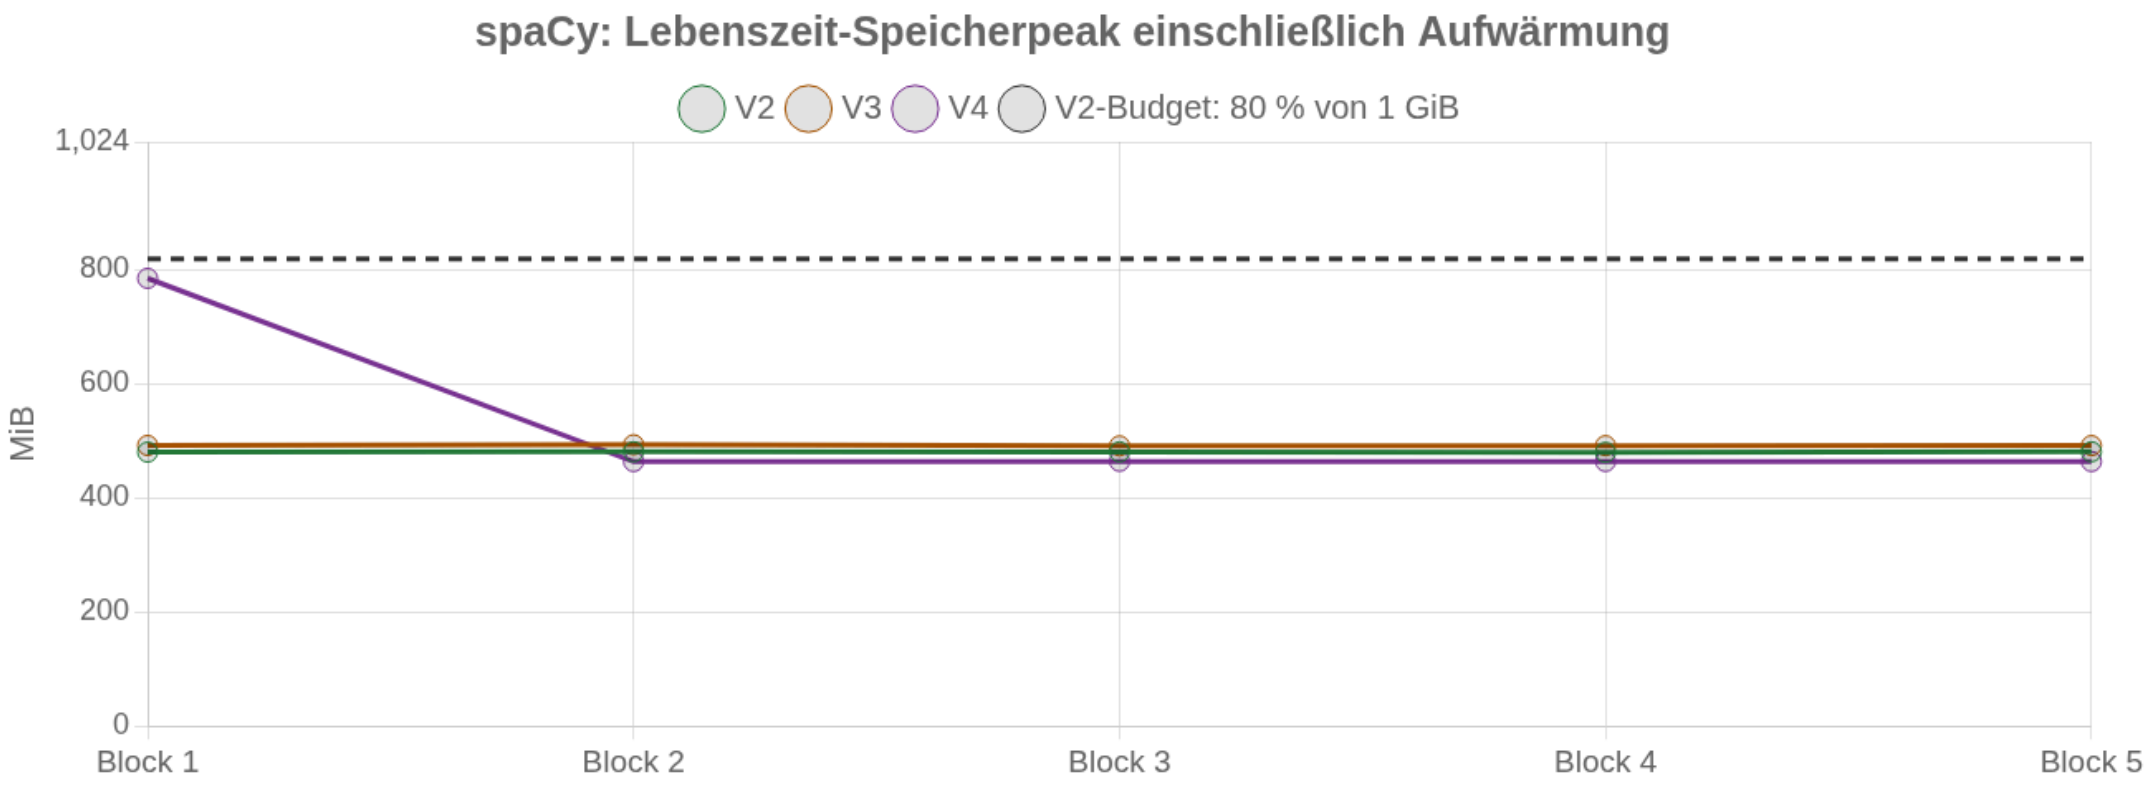
H1 und H2 werden dennoch nicht bestätigt

H1: V2 gegen V1	4 / 20 Aktionsvergleiche verfehlen die relative Grenze.
H2: V3/V4 gegen V1	6 / 40 Aktionsvergleiche verfehlen die relative Grenze.

- Block 1, Beitritt: 24,57 → 52,38 ms; +27,80 ms, aber +113,15 %.
- Block 5, V2-Q&A: +5,50 ms, aber +26,18 %.
- V1 in Block 1 bleibt erhalten; Ursache nicht zugeordnet.

Alle absoluten 50-ms-Grenzen bestehen. Auch V0→V1 zeigt drei relative Verletzungen; kein isolierter Kausalbeweis für spaCy.

V2 bleibt im Ressourcenbudget



V2: 479,87–480,89 MiB; CPU 18,67–19,11 % einer CPU; Drosselung 0,68–0,89 %. 750 / 750 Analysen erfolgreich; kein OOM-Zuwachs in der Reihe.

Störungen treffen vor allem die Analyse

- **V3:** 91,34–96,34 % gedrosselte Perioden; Analyse-p95 2.382,32–3.185,24 ms; 749 / 750 im Fenster erfolgreich.
- **V4:** 745 Fallbacks, 5 offene Analysen am Fensterende; Fallback-p95 5.048,95–5.058,46 ms.
- **V4-Transport:** 0 Weiterleitungen über die Proxy-Lebenszeit; Clientabbruch vor Ablauf der Verzögerung.

> V4 belegt Timeout-/Ersatzpfade, keine tatsächlich langsam rechnende spaCy-Inferenz.

Entscheidung: lexikalische Alternative beibehalten

- `NLP_ENABLED=false`; keine Freigabe durch Aufweichen der Kriterien.
- Für neue Versuche: untersuchtes Budget 1 CPU / 1 GiB / 64 PIDs beibehalten.
- Grenzen: gemeinsamer WSL2-Host, Beitrittswelle, kein Rendering-/LLM-Nachweis.

Diskussion: Welche Kontrolle könnte die niedrige V1-Baseline erklären? Welche Aussage erlaubt ein Containerlimit wirklich? Welchen Nutzen müsste Glättung gegenüber zusätzlichem Betrieb liefern?

Compose-Nachtrag: Rekonstruktion, keine damalige Aufnahme. KI: Umsetzung, Messausführung, Auswertung und Entwurf mit OpenAI Codex (GPT-6 laut Agentenumgebung). Niklas verantwortet persönliche Gegenprüfung und fachliche Freigabe. Belege im Handout; Auswertungsquelle 89d7d53b035e4ef8.