Ressourcenisolation auf dem Anwendungshost

Aufgabe 1A · Niklas · 12.11.2026 · Abgabeentwurf

> **Entscheidung:** spaCy für das untersuchte Freigabekriterium deaktiviert lassen. Ressourcen und absolute Live-Latenzen sind unauffällig; die vorab festgelegten relativen Grenzen werden jedoch nicht in allen Wiederholungen eingehalten.

1 Fragestellung und Systemgrenze

Kann die optionale Wortwolken-Lemmatisierung auf demselben Host laufen, ohne Beitritt, Quizstimme, Q&A-Einreichung und Tempostimme unzulässig zu verzögern? H1 prüft normalen spaCy-Betrieb gegen Analyse ohne spaCy; H2 prüft CPU-Drosselung und Verzögerung gegen dieselbe Baseline. Die ernsthafte Gegenalternative ist `NLP_ENABLED=false` mit lexikalischer Wortwolke [1, 2].

Baustein	Ort und Einordnung
spaCy	Separater CPU-Sidecar; Glättung von Wortformen, keine generative Inferenz.
8.9b und Kontextaufbau	Klassifikationspfad beziehungsweise Kontextaufbau im Backend-Prozess; keine eigenen Inferenzcontainer.
Encoder	Eigener Sidecar für Embeddings; im A1-Vergleich ausgeschaltet.
Generative Inferenz	Nach ADR-0035 eigene private Serverrolle; aus diesem spaCy-Versuch nicht ableitbar [3].

Kontrollierter Vergleich

Gemessen wurde der unveränderte Fork-`main` vom Commit `8f91e0417bc5aace461c3644a0b6b26c9284035b` (Version 1.4.0), gemäß dokumentierter Freigabe statt des ursprünglichen 1.3-Tags. Fünf deterministisch randomisierte Blöcke enthalten jede Variante einmal; keine Messung wird nach ihrem Ergebnis ausgeschlossen [2, 4].

Variante	Analyse bei identischer Live-Last
V0	Keine Analyse, spaCy aus.
V1	Lexikalische Analyse, spaCy aus.
V2	spaCy mit 1 CPU, 1 GiB RAM und 64 PIDs.
V3	Wie V2, aber 0,25 CPU.
V4	Wie V2; Weiterleitung um 6000 ms verzögert bei 5000 ms Client-Timeout.

Labor: Ubuntu 24.04.5 unter WSL2, Docker 29.9.2, cgroup v2, 16 logische CPUs, rund 15,57 GiB RAM. Anwendung, PostgreSQL, Redis, PDF-Worker und Lastgenerator teilen den Rechner; nur V2–V4 starten spaCy. Andere NLP-/Encoder-/LLM-Funktionen bleiben aus.

2 Live-Signale: schnell, aber nicht durchgehend innerhalb der relativen Grenze

Je Lauf: 60 s separate Aufwärmung, 300 s Messfenster, 500 geplante Beitritte über 90 s sowie 500 Quiz-, 100 Q&A- und 500 Tempostimmen. Die Ergebnisfreigabe ist für Sekunde 270 geplant. Fünf getrennte Analysesessions liefern zusammen 150 geplante Analysen je Fenster; jeweils 500 zulässige synthetische Fragen bleiben konstant [2, 4].

p95 wird pro Aktion und Lauf aus erfolgreichen Rohstichproben neu berechnet (Nearest Rank). Ein Kandidat darf gegenüber V1 desselben Blocks sowohl höchstens 10 % als auch höchstens 50 ms zulegen. Fehler und fehlende geplante Arbeit dürfen jeweils höchstens 0,5 % betragen; alle fünf Wiederholungen müssen bestehen.

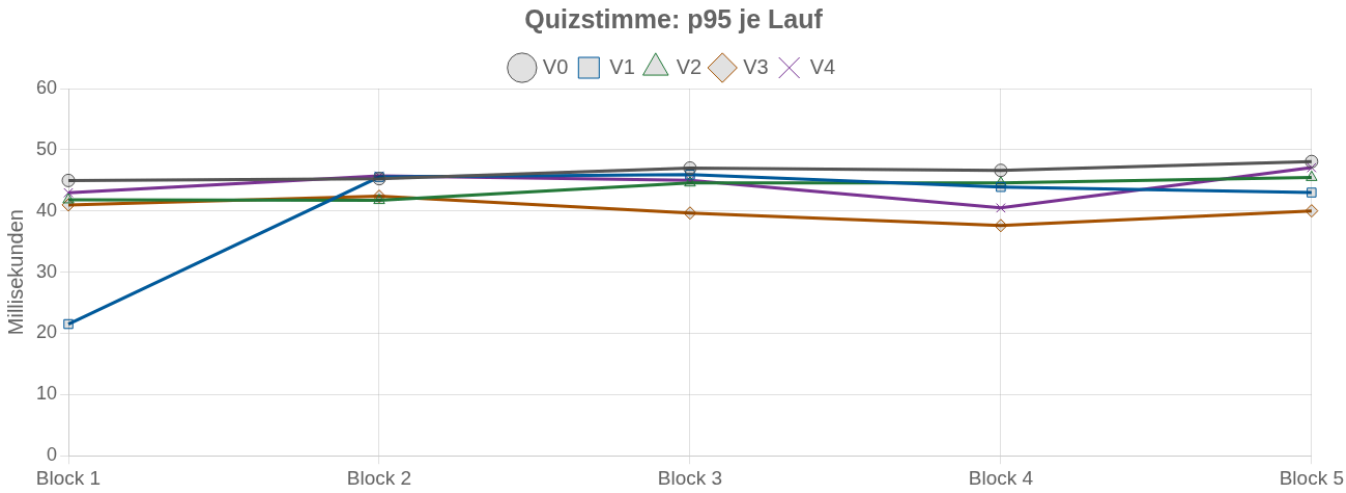


Abb. 1: Einzelne Lauf-p95, keine gepoolten Perzentile. Das absolute 1000-ms-Quizziel liegt oberhalb des dargestellten Bereichs. Quelle: eigene, agentengestützt ausgeführte Laborreihe [4, 5].

Regel	Ergebnis
H1: V2 gegen V1	**nicht bestätigt**; 4 von 20 Aktionsvergleichen verfehlen die relative Grenze.
H2: V3/V4 gegen V1	**nicht bestätigt**; 6 von 40 Aktionsvergleichen verfehlen die relative Grenze.
Absolutes Quizziel	Alle 25 Lauf-p95 unter 1000 ms; höchster Wert 48,07 ms.
Aktionen und Fehler	40000 von 40000 geplanten Aktionen erfolgreich im Messfenster; keine fehlgeschlagenen Versuche.

Beispiel Block 1, Beitritt: V1 rund 24,57 ms, V2 rund 52,38 ms. Der Anstieg von 27,80 ms besteht die absolute, aber mit rund 113,15 % nicht die relative Grenze. Zusätzlich verfehlt V2 in Block 5 bei Q&A die relative Grenze um rund 26,18 % bei nur 5,50 ms absolutem Anstieg. Die auffällig niedrige V1-Baseline in Block 1 bleibt im Ergebnis; ihre Ursache ist nicht zugeordnet.

Auch V0→V1 verfehlt in drei Aktionsvergleichen die relative Grenze. Der Versuch liefert daher keine saubere Ursachenzuordnung zu einer einzelnen Backendfunktion und keinen Beleg, dass spaCy allein die beobachteten Unterschiede verursacht.

3 Ressourcen und Analyseverfügbarkeit

Docker-/cgroup-Werte wurden alle zwei Sekunden erfasst: 151 Mess- und 31 getrennte Aufwärmstichproben je Lauf. CPU-Nutzung und Drosselung stammen aus Zählerdifferenzen derselben Containergeneration im Messfenster. `memory.peak` umfasst die Containerlebenszeit einschließlich Aufwärmung; er wird nicht von einem früheren Peak subtrahiert.

Verfügbarkeit meint hier LEMMA im Messfenster; korrekte lexikalische Fallbackantworten können weiterhin eine nutzbare Wortwolke liefern.

Normalbetrieb V2	Spannweite über fünf Wiederholungen
Mittlere CPU-Nutzung im Fenster	18,67–19,11 % einer CPU.
Gedrosselte CPU-Perioden	0,68–0,89 %; Grenze ≤ 5 % eingehalten.
Lebenszeit-Speicherpeak	479,87–480,89 MiB; Grenze ≤ 819,20 MiB (80 % von 1 GiB) eingehalten.
Analyseerfolg	750 / 750 ohne Fallback; Erfolgs-p95 489,09–510,51 ms.
OOM-Zähler	Kein Zuwachs bei den gemessenen Diensten in allen Varianten.

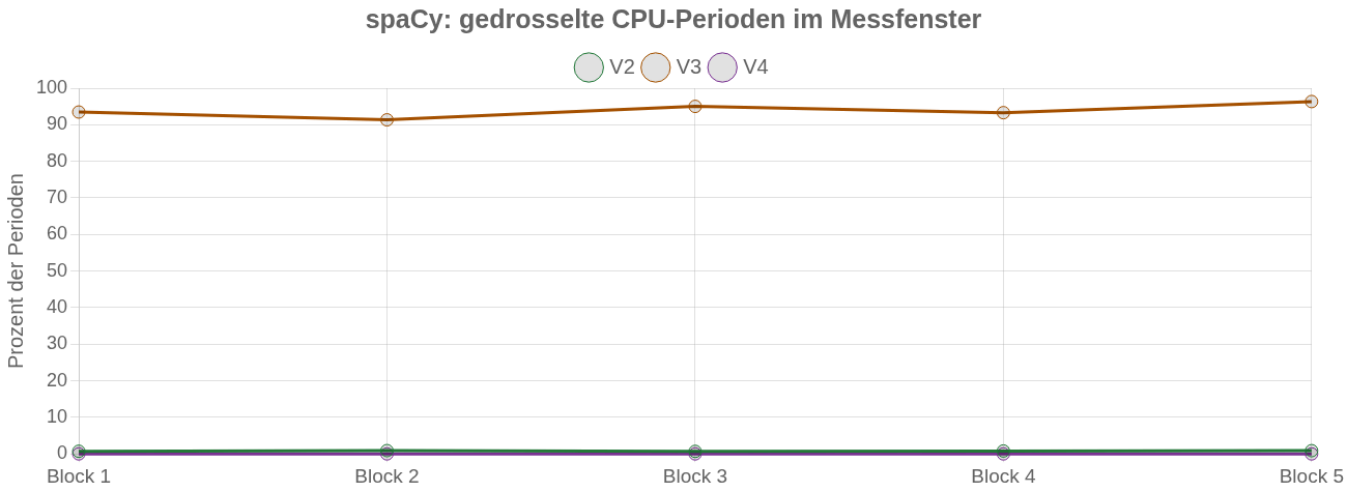


Abb. 2: Zuwachs gedrosselter Perioden geteilt durch Zuwachs aller Perioden; keine Subtraktion lebenslanger Quotienten [4, 5].

V3 mit 0,25 CPU erreicht 91,34–96,34 % gedrosselte Perioden. Der Erfolgs-p95 steigt auf 2.382,32–3.185,24 ms; 749 von 750 Analysen enden erfolgreich im Fenster, 1 bleibt am Fensterende offen. Damit ist die kleinere CPU-Zuteilung keine belegte gleichwertige Ersatzkonfiguration.

V4 liefert 745 Fallbackantworten und 5 am Fensterende offene Analysen, bei rund 5.048,95–5.058,46 ms Fallback-p95. Die Proxyzähler belegen 0 Weiterleitungen über ihre Lebenszeit einschließlich Aufwärmung: Abbrüche erfolgen vor den 6000 ms. V4 prüft daher Timeout, Rückstau und Ersatzpfad, nicht eine tatsächlich langsam rechnende spaCy-Inferenz. Der Grund `SIDECAR_UNAVAILABLE` kann im geprüften Client auch durch dessen Zwei-Anfragen-Grenze entstehen.

4 Betriebsentscheidung und Gültigkeitsgrenzen

> **Gegenalternative beibehalten:** `NLP_ENABLED=false`. Die vorab vereinbarte Freigabe ist trotz niedriger absoluter Live-Latenzen nicht vollständig belegt. Sprachliche Glättung rechtfertigt hier keine Aufweichung der Kriterien.

Für einen weiteren isolierten Versuch bleiben 1 CPU, 1 GiB RAM und 64 PIDs das untersuchte spaCy-Budget. Es ist keine Ressourcenreservierung für App, PostgreSQL oder Redis; diese Dienste hatten keine zusätzlichen eigenen Limits. Eine Absenkung auf 0,25 CPU erhöht die Drosselung deutlich und wird nicht als gleichwertige Einsparung empfohlen. Aus dem Speicherverbrauch folgt keine geprüfte Freigabe eines kleineren RAM-Limits.

Betriebsaufwand entsteht durch Imagepflege, Modellstart und Healthcheck, Socket-Zuordnung, Ressourcenüberwachung sowie die Kontrolle von Timeouts und Fallbacks. Deaktivierung spart Sidecar-Betrieb und Modellpflege, verliert aber die Zusammenführung von Flexionsformen. Eine Wirtschaftlichkeitsrechnung mit Eurobeträgen oder eine didaktische Nutzensteigerung wurde nicht gemessen.

Die Ergebnisse gelten für eine Beitrittswelle auf einem gemeinsam genutzten WSL2-Rechner. Sie bestätigen weder dauerhaft 500 aktive Clients noch die 8-vCPU-Zielumgebung, Browser-Rendering, Kompassaktualität bis zur sichtbaren Anzeige oder zusätzliche LLM-Tragfähigkeit. Für eine neue Freigabe wäre ein gesonderter Versuch mit externer Lasterzeugung und klar zugeordneter Zielhardware sinnvoll; die jetzigen Blöcke bleiben unverändert erhalten.

Nachvollziehbarkeit

Die vollständige Reihe umfasst 25 Läufe unter `docs/referat-thema-1/evidenz/1A/reihe-2026-11-12/`. JSON, CSV und Tabellen unter `evidenz/1A/auswertung/` enthalten alle gepaarten Einzelvergleiche und Ressourcenwerte. SHA-256-Prüfsummen binden die Auswertung an ihre Eingaben; Dokumentquelle: `89d7d53b035e4ef8`. Die vorher abgebrochene Reihe und die Vorläufe sind gesondert erhalten und nicht eingemischt.

Nachtrag 13.11.2026: Die aufgelöste Compose-Ausgabe wurde damals nicht gespeichert. Fünf heutige Rekonstruktionen wurden gegen die 25 Manifeste abgeglichen; sie ersetzen keine damalige Aufnahme. Dieser Nachweisunterschied bleibt vor vollständiger Abnahme zu bewerten.

Eigenanteil und KI-Unterstützung

Auftrag, schrittweise Freigaben, Laborbereitstellung und Git-Übernahmen sind Niklas zugeordnet. Implementierung, Tests, Messausführung, Berechnung und dieser Text wurden mit OpenAI Codex (GPT-6 laut Agentenumgebung) erstellt. Die persönliche Gegenprüfung der Zahlen, Betriebsentscheidung und fachliche Vertretung müssen durch Niklas erfolgen; dieser Entwurf ersetzt keine Eigenständigkeitserklärung. Wesentliche KI-Aufträge und die persönliche Prüfliste stehen in `1A-abschluss-und-uebergabe.md`. Formale Zitation und erlaubter KI-Umfang sind vor Abgabe anhand des Prüfungsauftrags beziehungsweise myCampus zu bestätigen.

Quellen und Belege

1. Prüfungsspezifikation im Repository: CLOUD-COMPUTING-REFERAT-PRUEFUNG.md, Abschnitte 4.1.3 und 4.3.
2. A1-Versuchsvertrag, Version 2, vor den bestätigenden Messungen festgehalten.
3. ADR-0035; geprüfte Anwendung: Commit 8f91e0417bc5aace461c3644a0b6b26c9284035b.
4. Eigene Laborreihe vom 12.11.2026, Laufmanifeste und komprimierte Ressourcenzeitreihen; Aufbau in 1A-versuchsreihe.md.
5. Reproduzierbare Auswertung durch scripts/load/evaluate-resource-isolation.mjs; ungerundete Prüfwerte in JSON und CSV.